

CONTEXTO DEL PROYECTO

Generación de Datos Sintéticos para la Evaluación de
Recursos Hídricos del Río Reconquista

Universidad Nacional del Oeste

Instituto de Ingeniería y Nuevas Tecnologías

Autor: Marcelo Fabián Esperanza

Director: Dr. Enrique Fernández

Documento de Contexto — 2024

Resumen del Documento

El presente documento desarrolla en profundidad el contexto del proyecto de investigación denominado *"Elaboración de un modelo para la determinación del Índice de Calidad del Agua en aguas superficiales de la Cuenca Alta del Río Reconquista en el partido de Merlo"*, llevado a cabo en el Instituto de Ingeniería y Nuevas Tecnologías de la Universidad Nacional del Oeste. Se examinan las dimensiones ambientales, sociales, tecnológicas e institucionales del problema, así como las estrategias propuestas para abordarlo mediante la generación de datos sintéticos y técnicas de inteligencia artificial.

Tabla de Contenidos

- 1. Introducción y Justificación del Proyecto
- 2. El Río Reconquista: Historia, Geografía y Estado Ambiental
 - 2.1 Historia del Río Reconquista
 - 2.2 Geografía de la Cuenca
 - 2.3 Estado Actual de Contaminación
- 3. Problemática de la Calidad del Agua en la Cuenca
 - 3.1 Fuentes de Contaminación
 - 3.2 Impacto en la Salud Pública
 - 3.3 Impacto en los Ecosistemas
- 4. El Índice de Calidad del Agua (ICA): Marco Conceptual
- 5. Parámetros de Monitoreo y Puntos de Muestreo
- 6. Problemática de Escasez de Datos en la Investigación
- 7. Estrategias de Generación de Datos Sintéticos
 - 7.1 Simulación de Montecarlo
 - 7.2 Redes Neuronales Autoencoders
 - 7.3 Comparación de Métodos
- 8. Marco Institucional y Vinculación con el Ámbito Laboral
- 9. Aplicaciones Prácticas e Impacto Potencial
- 1
- 0. Limitaciones y Consideraciones Metodológicas
- 1
- 1. Trabajos Relacionados y Estado del Arte
- 1
- 2. Transferencia de Resultados y Perspectivas Futuras
- 1
- 3. Conclusiones del Contexto

1. Introducción y Justificación del Proyecto

La gestión sostenible de los recursos hídricos constituye uno de los desafíos más críticos de la era contemporánea. A nivel global, la creciente demanda de agua para consumo humano, actividades agrícolas, industriales y recreativas, sumada al deterioro progresivo de la calidad de los cuerpos de agua superficiales, configura un escenario de alta complejidad que exige respuestas innovadoras y efectivas por parte de la comunidad científica y los organismos de gestión.

En este contexto, el proyecto de investigación radicado en el Instituto de Ingeniería y Nuevas Tecnologías de la Universidad Nacional del Oeste (UNO) surge como respuesta a una problemática concreta y urgente: la ausencia de datos históricos y la escasez de recursos para el monitoreo continuo de la calidad del agua en la Cuenca Alta del Río Reconquista, en el partido de Merlo, provincia de Buenos Aires, Argentina.

El Río Reconquista, segundo cuerpo de agua más contaminado de la provincia de Buenos Aires, atraviesa uno de los corredores urbanos e industriales más densamente poblados del país. Su deterioro ambiental acumulado a lo largo de décadas, resultado de vertidos industriales, efluentes domiciliarios sin tratamiento y prácticas agrícolas inadecuadas, representa no solo un problema ecológico de gran magnitud, sino también un riesgo concreto para la salud pública de las comunidades que habitan en sus márgenes.

La construcción de un modelo predictivo basado en inteligencia artificial para determinar el Índice de Calidad del Agua (ICA) del río requiere, de manera ineludible, contar con volúmenes significativos de datos de calidad. Sin embargo, los procesos de recolección y análisis de muestras son lentos, costosos y logísticamente complejos, lo que hace que la obtención de la cantidad necesaria de datos llevaría años con los recursos disponibles.

Ante esta realidad, el trabajo de Esperanza (2024) propone y evalúa el uso de técnicas de generación de datos sintéticos como solución complementaria: la Simulación de Montecarlo y las Redes Neuronales Autoencoders (en particular el Variational Autoencoder). Estas técnicas permiten ampliar artificialmente el conjunto de datos disponible, respetando las distribuciones estadísticas y las correlaciones observadas en los datos reales, de modo de poder avanzar con el desarrollo del modelo sin necesidad de esperar años para obtener suficientes muestras.

El presente documento desarrolla en profundidad el contexto de este proyecto: su justificación ambiental y social, el estado del arte en la materia, el marco institucional, la caracterización del sistema hídrico estudiado y las estrategias metodológicas adoptadas.

2. El Río Reconquista: Historia, Geografía y Estado Ambiental

2.1 Historia del Río Reconquista

En la primera mitad del siglo XX, el Río Reconquista —también denominado históricamente Río de las Conchas debido a la abundante población de moluscos que albergaba— poseía aguas cristalinas y una rica biodiversidad. Sus costas eran utilizadas por la población local como espacio de recreación y balneario, evidencia de un ecosistema acuático saludable y vibrante.

La situación comenzó a cambiar drásticamente con la industrialización de la región. A partir de la década de 1940, el establecimiento de industrias en la ribera del río, junto con el crecimiento explosivo de asentamientos urbanos en su cuenca, inició un proceso sostenido de degradación ambiental. Los efluentes industriales y domiciliarios, volcados sin tratamiento previo, fueron deteriorando progresivamente la calidad de las aguas. Para la década de 1950, bañarse en el río ya resultaba peligroso para la salud humana.

Décadas después, el Río Reconquista se convirtió en el segundo cuerpo de agua más contaminado de la provincia de Buenos Aires, superado únicamente por la cuenca Matanza-Riachuelo. Esta denominación refleja un proceso de deterioro acelerado, producto de la ausencia de políticas efectivas de gestión ambiental y de la presión creciente de una de las regiones urbanas más densamente pobladas de Latinoamérica.

2.2 Geografía de la Cuenca

El sistema hídrico del Río Reconquista abarca un total de 92 kilómetros, desde su nacimiento en la confluencia de los arroyos La Chocha y El Durazno, en el Partido de General Rodríguez, hasta su desembocadura en el Río Luján. La cuenca del Reconquista integra, junto con las cuencas del Matanza-Riachuelo, del Río Luján y de los arroyos del sur, la Región Metropolitana de Buenos Aires.

El río articula tres tramos principales con características diferenciadas:

Tramo	Características Principales	Fuentes de Contaminación
Cuenca Alta	Zona de nacimiento. Arroyos La Chocha y El Durazno como afluentes principales. Partido de General Rodríguez y Merlo.	Contaminación agrícola (pesticidas, fertilizantes). Menor impacto domiciliario e industrial.
Cuenca Media	Recibe aportes de los arroyos Las Catonas y Morón. Aumenta la densidad poblacional.	Vertidos textiles y de curtiembres. Efluentes domiciliarios e industriales crecientes.
Cuenca Baja	El cauce se divide en tres ramales: Río Tigre, Reconquista Chico y Canal Aliviador.	Máxima degradación acumulada. Industria metal-mecánica y textil. Efluentes domésticos.

Tabla 1. Caracterización por tramos del Río Reconquista.

2.3 Estado Actual de Contaminación

En la actualidad, el Río Reconquista es receptor de efluentes domésticos, agrícolas e industriales provenientes de una cuenca donde se han asentado millones de personas y miles de industrias. La falta de tratamiento adecuado de los residuos ha provocado un deterioro alarmante, según reportes de la Autoridad de Cuenca Matanza-Riachuelo (ACUMAR, 2022).

Las principales restricciones actuales para el uso del río incluyen: la imposibilidad de proteger adecuadamente la vida acuática, la prohibición de actividades recreativas con contacto directo, la no aptitud para consumo animal, severas limitaciones para uso industrial y la necesidad de tratamientos especiales para cualquier consideración de uso humano potabilizable.

Existe también una amenaza adicional para las aguas subterráneas de la cuenca, particularmente la capa freática, lo que afecta de manera desproporcionada a los hogares de menores recursos que dependen del agua subterránea para sus necesidades diarias.

3. Problemática de la Calidad del Agua en la Cuenca

3.1 Fuentes de Contaminación

La contaminación del Río Reconquista es de naturaleza múltiple y compleja, involucrando fuentes puntuales y difusas de origen diverso. La Autoridad de Cuenca Matanza-Riachuelo (ACUMAR) y múltiples estudios científicos han identificado las siguientes categorías principales de contaminantes:

Desechos Orgánicos	Residuos producidos por humanos y ganado. El exceso de bacterias aeróbicas agota el oxígeno, perjudicando la vida acuática. Se mide mediante la Demanda Bioquímica de Oxígeno (DBO).
Efluentes Industriales	Vertidos de industrias textiles, curtiembres, metal-mecánica y química. Aportan metales pesados (mercurio, plomo, cadmio), contaminantes orgánicos y sustancias tóxicas.
Agroquímicos	Pesticidas y herbicidas provenientes de actividades agrícolas en la cuenca alta. Causan daños a la fauna acuática y pueden contaminar fuentes de agua para consumo humano.
Efluentes Domiciliarios	Aguas residuales sin tratamiento adecuado, que aportan nutrientes (fósforo, nitrógeno), patógenos y materia orgánica.
Residuos Sólidos	Disposición informal de residuos urbanos en márgenes y cauces del río. Generan contaminación visual, obstrucción del cauce y lixiviados tóxicos.

3.2 Impacto en la Salud Pública

El deterioro de la calidad del agua del Río Reconquista tiene consecuencias directas e indirectas sobre la salud de las comunidades que habitan en su cuenca. La contaminación con sustancias físicoquímicas por encima de los valores máximos establecidos genera riesgos concretos para la salud humana, incluyendo enfermedades gastrointestinales, infecciones dérmicas, y en casos de exposición prolongada, mayor riesgo de enfermedades crónicas.

Las poblaciones más vulnerables son aquellas de menores recursos que habitan en los márgenes del río y carecen de acceso a servicios de saneamiento adecuados. Para estos grupos, la contaminación de las napas freáticas representa un riesgo adicional, ya que dependen del agua subterránea para su consumo cotidiano.

3.3 Impacto en los Ecosistemas Acuáticos

La biodiversidad acuática del Río Reconquista ha sufrido una reducción dramática como consecuencia de la contaminación acumulada. Los organismos más sensibles han desaparecido, y los ecosistemas acuáticos presentan signos evidentes de eutrofización,

hipoxia y pérdida de biodiversidad.

Los niveles de oxígeno disuelto inferiores a 5 mg/L, frecuentes en los tramos más contaminados, configuran condiciones de hipoxia que resultan letales para la mayoría de las especies de peces y otros organismos acuáticos. Esta situación impacta además en la cadena trófica completa y en la capacidad de autorregulación del ecosistema.

4. El Índice de Calidad del Agua (ICA): Marco Conceptual

Los Índices de Calidad del Agua (ICA) han surgido como herramientas relativamente simples y eficaces para evaluar el estado de los recursos hídricos y orientar la toma de decisiones en materia de gestión ambiental y políticas públicas. Su principal fortaleza radica en la capacidad de sintetizar información técnica compleja —procedente de múltiples parámetros físicos, químicos y biológicos— en un único valor numérico de fácil interpretación.

El concepto de calidad del agua no es absoluto: está profundamente vinculado a los usos específicos a los que se destina el recurso. Así, los estándares de calidad varían según se trate de agua para consumo humano, riego agrícola, uso industrial, recreación con o sin contacto directo, o protección de ecosistemas acuáticos. Esta relación con el uso previsto es fundamental para la construcción y aplicación adecuada de los índices.

El proyecto de investigación de la UNO se orienta específicamente a construir un ICA adaptado a las características locales de la Cuenca Alta del Río Reconquista, con foco inicial en el uso recreativo del recurso hídrico. Estudios previos sugieren que el índice debería integrar, entre otros, los siguientes parámetros: Oxígeno Disuelto (OD), Demanda Bioquímica de Oxígeno a 5 días (DBO5), Demanda Química de Oxígeno (DQO), Fósforo Total, Nitrógeno Amoniacal, Sólidos Suspendidos Totales, Conductividad Eléctrica, Escherichia coli, pH, Cromo Total, Plomo Total e Hidrocarburos Totales.

La estructura matemática del ICA suele basarse en fórmulas que integran subíndices para cada parámetro, ponderados según su importancia relativa para el uso previsto. Los ICA basados en ecuaciones multiplicativas son preferidos respecto de los aditivos, ya que son más sensibles a variaciones en la calidad del agua y evitan el fenómeno de 'eclipsamiento', que ocurre cuando se calcula un valor satisfactorio aunque uno o varios parámetros presenten alteraciones.

«Los ICA no ofrecen una visión completa por sí mismos y no deberían ser la única herramienta para evaluar la calidad del agua. Es recomendable combinarlos con otros métodos y herramientas de diagnóstico para obtener una imagen más precisa y detallada de la salud del ecosistema acuático.»
— Anastopoulos & Kyzas, 2015

5. Parámetros de Monitoreo y Puntos de Muestreo

El programa de muestreo del proyecto contempla la medición sistemática de 12 parámetros físicoquímicos en cinco puntos estratégicamente seleccionados de la Cuenca Alta del Río Reconquista, en el partido de Merlo. Los datos recolectados hasta la fecha comprenden 283 muestras analizadas entre junio de 2023 y junio de 2024, con una frecuencia de entre una y dos tomas semanales.

Parámetros Medidos

Parámetro	Símbolo	Relevancia Ambiental
Temperatura del agua	T°	Influye en la solubilidad de gases y contaminantes; afecta procesos bioquímicos.
pH	pH	Indica acidez o alcalinidad. Rango aceptable para vida acuática: 6.5–8.5.
Conductividad Eléctrica	CE	Indicador de iones disueltos. Alta correlación con nitratos y fosfatos.
Sólidos Totales Disueltos	STD	Concentración total de materiales disueltos, incluyendo sales y minerales.
Oxígeno Disuelto	OD	Esencial para la vida acuática. Valores < 5 mg/L indican hipoxia letal.
Sólidos Totales en Suspensión	SST	Partículas suspendidas. Indicador de erosión y otras fuentes de contaminación.
Turbidez	NTU	Claridad del agua. Afecta fotosíntesis de organismos acuáticos.
Cloruros	Cl-	Indicador de salinidad y posible contaminación industrial.
Dureza del agua	dH	Concentración de calcio y magnesio. Afecta disponibilidad de nutrientes.
Nivel del río	Nivel	Medida de la dinámica del flujo. Influenciado por factores climáticos.
Temperatura de la muestra	T°m	Temperatura al momento del análisis en laboratorio.
Humedad	H%	Vapor de agua en el aire durante la recolección. Afecta algunos parámetros físicos.

Tabla 2. Parámetros físicoquímicos medidos en el programa de monitoreo.

Puntos de Muestreo

Se seleccionaron cinco puntos estratégicos que permiten obtener una caracterización representativa de la calidad del agua en el tramo de la cuenca alta correspondiente al partido

de Merlo. Tres puntos se ubican sobre la traza central del río y dos sobre arroyos tributarios:

Punto	Descripción	Observaciones
Puente Bilbao	Sobre la traza central del río.	Primer punto aguas arriba. Menor influencia industrial.
Puente Bernardo de Irigoyen	Sobre la traza central del río.	Punto intermedio. Permite detectar variaciones.
Puente Falbo	Sobre la traza central del río.	Tercer punto sobre el río principal.
Arroyo Las Torres	Afluente a cielo abierto.	Mayor exposición a desechos urbanos y residuos.
Arroyo Salguero	Afluente entubado.	Mejores resultados en CE, STD, SST, turbidez y cloruros. Protegido de desechos urbanos directos.

Tabla 3. Puntos de muestreo del programa de monitoreo.

6. Problemática de Escasez de Datos en la Investigación

La escasez de datos constituye uno de los problemas más recurrentes y limitantes en proyectos de investigación que involucran sistemas complejos, especialmente en contextos con restricciones presupuestarias. Esta problemática no es exclusiva del monitoreo hídrico: aparece también en la investigación biomédica (enfermedades raras), en el análisis de datos acústicos, en la vigilancia por videovigilancia y en muchos otros dominios.

En el caso específico del proyecto de la UNO, los factores que limitan la obtención de datos son:

- Costo elevado de reactivos e insumos químicos para el análisis de laboratorio.
- Logística compleja para la recolección de muestras en campo.
- Procesos de análisis extensos (algunos llevan días, como la DBO5).
- Ausencia de presupuesto para instalación de sensores automáticos basados en IoT.
- Falta de datos históricos de registros previos con calidad y continuidad adecuadas.
- Limitación de capacidad analítica: solo una o dos muestras por semana.
- Ausencia de colaboración externa con otras entidades que pudieran aportar recursos.

Las implicancias estadísticas de contar con pocos datos son significativas y bien documentadas en la literatura científica. La Ley de los Grandes Números establece que a medida que aumenta el tamaño muestral, la media muestral converge hacia la media poblacional verdadera. El Teorema Central del Límite garantiza la normalidad asintótica de las distribuciones solo cuando la cantidad de datos es suficientemente grande. Y el error estándar de estimación disminuye en proporción a la raíz cuadrada del tamaño muestral.

Con solo 283 muestras recolectadas entre junio de 2023 y junio de 2024, y a un ritmo de no más de dos muestras semanales, el equipo de investigación proyecta que la obtención de un volumen de datos estadísticamente robusto llevaría varios años. Esta limitación temporal compromete seriamente la viabilidad del proyecto en sus plazos esperados.

El problema se agrava cuando se considera que los algoritmos de aprendizaje automático y aprendizaje profundo, que constituyen el núcleo de la solución propuesta, requieren grandes volúmenes de datos para entrenarse adecuadamente. Los modelos entrenados con pocos datos tienden a presentar sobreajuste (overfitting), baja capacidad de generalización y rendimiento inconsistente en la práctica.

7. Estrategias de Generación de Datos Sintéticos

Ante la imposibilidad de obtener rápidamente la cantidad de datos reales necesaria, el proyecto adopta una estrategia de Data Augmentation mediante la generación de datos sintéticos. Los datos sintéticos son datos artificialmente generados que imitan las propiedades estadísticas, distribuciones y correlaciones de los datos reales, sin constituir réplicas exactas.

7.1 Simulación de Montecarlo

El método de Montecarlo es una técnica de simulación estocástica ampliamente utilizada en ciencias naturales, ingeniería y finanzas. Su principio fundamental consiste en generar múltiples muestras aleatorias a partir de distribuciones de probabilidad ajustadas a los datos observados, con el fin de estimar el comportamiento de un sistema complejo.

En el contexto del proyecto, el proceso de simulación sigue los siguientes pasos: (1) cálculo de estadísticos descriptivos (media y desviación estándar) de cada parámetro a partir de los datos reales disponibles; (2) ajuste de una función de distribución de probabilidad apropiada; (3) generación de N muestras aleatorias mediante un generador de números pseudoaleatorios; (4) validación de los datos generados para asegurar que todos los valores se encuentren dentro de rangos físicamente admisibles.

Para garantizar la calidad de los datos generados se evaluaron múltiples estrategias de corrección de valores inadmisibles (como valores negativos en parámetros que por definición son no negativos), entre ellas: truncamiento en valores extremos, uso de distribuciones no negativas (log-normal, gamma, Weibull), re-simulación, y transformación previa de los datos mediante la transformación de Box-Cox.

Los mejores resultados se obtuvieron con la estrategia de Transformación Box-Cox, que logró un puntaje general de similitud del 88.77% (Column Shapes Score: 88.62%; Column Pair Trends Score: 88.93%), según la evaluación con la biblioteca SDMetrics de Python.

7.2 Redes Neuronales Autoencoders (VAE)

Los Autoencoders son modelos de aprendizaje profundo no supervisado que aprenden representaciones comprimidas (espacio latente) de los datos de entrada y los reconstruyen en la salida. En particular, el Variational Autoencoder (VAE) introduce un enfoque probabilístico: en lugar de aprender una representación fija, aprende una distribución de probabilidad en el espacio latente, lo que permite generar nuevas muestras al muestrear distintos puntos de esa distribución.

La arquitectura implementada para el VAE en este proyecto toma como entrada un vector de 12 características (los parámetros medidos) y codifica la información en un espacio latente de 4 dimensiones. El modelo fue optimizado iterativamente, evaluando el impacto de cambios en el número de capas, neuronas, funciones de activación, optimizador (Adam), función de pérdida (MSE + divergencia KL) y épocas de entrenamiento.

El VAE alcanzó un puntaje general de similitud del 89.26% (Column Shapes Score: 84.62%; Column Pair Trends Score: 93.91%), superando al método de Montecarlo en la captura de relaciones entre pares de columnas —aspecto clave para preservar las correlaciones entre los parámetros del agua.

7.3 Comparación de Métodos

Los resultados obtenidos evidencian que ambos enfoques son viables y complementarios para el objetivo del proyecto, con fortalezas diferenciadas:

Aspecto	Montecarlo (Box-Cox)	Variational Autoencoder
Puntaje general	88.77%	89.26%
Column Shapes Score	88.62% (mejor)	84.62%
Column Pair Trends Score	88.93%	93.91% (mejor)
Fortaleza principal	Mejor reproducción de distribuciones marginales individuales.	Mejor captura de relaciones y correlaciones entre variables.
Rendimiento con pocos datos	Superior: no requiere grandes volúmenes para funcionar.	Mejora a medida que aumenta el dataset real.
Complejidad de implementación	Menor. Basada en estadística clásica.	Mayor. Requiere diseño de arquitectura y ajuste iterativo.

Tabla 4. Comparación de desempeño entre Montecarlo y VAE.

8. Marco Institucional y Vinculación con el Ámbito Laboral

El proyecto se desarrolla en el marco del Instituto de Ingeniería y Nuevas Tecnologías de la Universidad Nacional del Oeste (UNO), institución pública argentina con sede en el partido de Morón, provincia de Buenos Aires. La UNO tiene como misión la formación de profesionales y la generación de conocimiento orientados al desarrollo social, tecnológico y productivo de la región.

El proyecto cuenta con la participación de un equipo interdisciplinario que combina experiencia en informática, ingeniería química y ciencias ambientales, lo que garantiza la integración de perspectivas complementarias para abordar la complejidad del problema.

Institución	Universidad Nacional del Oeste (UNO)
Unidad ejecutora	Instituto de Ingeniería y Nuevas Tecnologías
Área geográfica	Partido de Merlo, Cuenca Alta del Río Reconquista
Director del proyecto	Dr. Enrique Fernández
Asesor metodológico	Carlos Neil
Colaborador	Marcelo Estevez
Autor del trabajo final	Marcelo Fabián Esperanza
Año de inicio del monitoreo	Junio de 2023
Período de datos disponibles	14/06/2023 – 18/06/2024
Total de muestras analizadas	283 muestras en 5 puntos de muestreo

La relevancia del proyecto trasciende el ámbito académico. La generación de datos sintéticos de calidad, que permitan avanzar en el entrenamiento de modelos de inteligencia artificial, tiene implicancias directas para la gestión ambiental del recurso hídrico: permite obtener resultados preliminares que justifican la continuación del proyecto, facilita la búsqueda de financiamiento externo y patrocinio institucional, y aporta conocimiento transferible a otros proyectos de monitoreo hídrico en la región.

Trabajos presentados en congresos y publicaciones vinculadas al proyecto incluyen: la presentación en el XXVI Workshop de Investigadores en Ciencias de la Computación (2024), el XXX Congreso Argentino de Ciencias de la Computación (CACIC, 2024), y una publicación en la Revista Ingeniería Sanitaria y Ambiental (2023).

9. Aplicaciones Prácticas e Impacto Potencial

Los resultados del proyecto tienen potencial de impacto en múltiples dimensiones:

Gestión Ambiental	Proporciona información continua sobre la calidad del agua para la toma de decisiones en políticas públicas de conservación y saneamiento hídrico.
Salud Pública	Permite identificar situaciones de riesgo para las comunidades que habitan en las márgenes del río y dependen de sus aguas.
Política y Regulación	Contribuye a la formulación de políticas basadas en datos precisos sobre calidad del agua, incluyendo límites permisibles de contaminantes.
Conservación de Ecosistemas	Facilita la identificación de áreas críticas y la evaluación del impacto de actividades humanas sobre los ecosistemas acuáticos.
Industria Agrícola	Permite evaluar riesgos asociados al uso de agua para riego y su impacto potencial en la cadena alimentaria.
Investigación Futura	Provee una base de datos y modelos transferibles para estudios sobre variaciones espaciales, estacionales y en otras cuencas.
Reducción de Costos	La disponibilidad de datos sintéticos de calidad reduce la dependencia de muestreos costosos y permite avanzar más rápido en el desarrollo de modelos.

10. Limitaciones y Consideraciones Metodológicas

El proyecto reconoce de manera explícita un conjunto de limitaciones que condicionan el alcance de sus conclusiones y que deben tenerse presentes al interpretar los resultados:

Tamaño de la muestra real	Con solo 283 muestras, las conclusiones estadísticas tienen un carácter preliminar y no pueden generalizarse con plena confianza. El enfoque iterativo adoptado prevé revisiones sucesivas a medida que crezca el dataset real.
Error de simulación	Los datos sintéticos incorporan un error respecto de los datos reales que puede ser significativo cuando la muestra base es pequeña. Este error es difícil de cuantificar con precisión y puede propagarse a los modelos entrenados con datos sintéticos.
Parámetros no medidos	Por restricciones presupuestarias, el proyecto no incluye medición de variables biológicas, metales pesados, contaminantes orgánicos ni parámetros estéticos. Esto limita la completitud del ICA construido.
Ausencia de monitoreo automático	La falta de sensores IoT impide el monitoreo continuo y en tiempo real, lo que restringe la capacidad de detectar eventos de contaminación súbita o variaciones temporales de alta frecuencia.
Colinealidad entre variables	Se detectaron correlaciones altas entre algunas variables (p.ej. cloruros, conductividad eléctrica y STD), lo que genera colinealidad en los modelos de regresión. Se requieren técnicas de selección o transformación de variables para abordar este problema.
Representatividad geográfica	El estudio se limita a la cuenca alta del río en el partido de Merlo. La generalización de resultados a otros tramos o cuencas requiere validación adicional.

11. Trabajos Relacionados y Estado del Arte

La predicción de la calidad del agua mediante técnicas de inteligencia computacional es un campo activo de investigación a nivel global. La revisión sistemática de la literatura muestra que las Redes Neuronales Artificiales (RNA) constituyen el paradigma más utilizado, seguido por las Máquinas de Vectores de Soporte (MVS) y los métodos de ensamble. Asimismo, los modelos híbridos que combinan enfoques estadísticos y basados en IA han demostrado consistentemente mejores resultados que los métodos individuales.

Referencia	Contribución Principal	Técnica Utilizada
López et al. (2016)	Revisión sistemática de técnicas IC para predicción de calidad del agua.	RNA, MVS, Computación Evolutiva
Faruk (2010)	Modelo híbrido ARIMA-RNA para series temporales de calidad de agua.	ARIMA + RNA (modelo híbrido)
Castellar & Salcedo (2020)	Modelo RNA para predicción de DBO en aguas marinas. $R > 0.9$.	Perceptrón Multicapa, Levenberg-Marquardt
Marshall Boehmwald (2022)	Evaluación comparativa de GAN, VAE y Gaussian Copula para datos sintéticos en salud.	GAN, VAE, Gaussian Copula
Lasso et al. (2023)	TVAE para generación de datos en investigación biomédica. 87-90% similitud.	TVAE (adaptación tabular de VAE)
Carmona Aguiar (2023)	VAE y CVAE para generación de datos acústicos sintéticos.	VAE, CVAE
Franco et al. (2023)	Revisión de sensores IoT y ML para monitoreo de calidad en acuíferos latinoamericanos.	IoT + Machine Learning
Basílico et al. (2015)	Desarrollo de índices ICAP e ICRP para arroyos pampeanos (La Choza y El Durazno).	Índices de calidad adaptados

Tabla 5. Selección de trabajos relacionados.

12. Transferencia de Resultados y Perspectivas Futuras

La solución desarrollada en el presente proyecto tiene vocación de transferibilidad más allá del caso específico del Río Reconquista. La escasez de datos sobre calidad del agua es una problemática común en numerosas regiones, especialmente en países en desarrollo, donde la brecha en disponibilidad de datos respecto de los países desarrollados continúa ampliándose (Castro et al., 2014).

Para que la solución sea efectivamente transferible, se requiere que el sistema de generación de datos sintéticos sea adaptable a diferentes contextos geográficos y tipos de uso del agua. Esto implica, entre otros aspectos:

- Incorporar mayor cantidad de parámetros físicoquímicos y biológicos, incluyendo metales pesados, contaminantes orgánicos y nutrientes.
- Extender el programa de muestreo a otras secciones de la cuenca y a cuencas adyacentes.
- Evaluar la aplicabilidad del modelo a diferentes usos del agua: consumo humano, riego agrícola, uso industrial y recreativo.
- Integrar el sistema de generación de datos sintéticos en programas de monitoreo institucionales.
- Explorar las técnicas de Gaussian Copula y Generative Adversarial Networks (GAN) como alternativas adicionales a Montecarlo y VAE.
- Desarrollar el componente de despliegue del modelo (fase no abordada en el trabajo actual) para poner a disposición de gestores e investigadores los resultados.

Los trabajos futuros identificados incluyen también la corroboración de los resultados preliminares de regresión lineal (variable cloruros inferida a partir de conductividad eléctrica) con el dataset sintético ampliado, la exploración sistemática de todas las relaciones entre variables mediante técnicas avanzadas de minería de datos y la construcción progresiva del modelo de determinación del ICA.

13. Conclusiones del Contexto

El proyecto de investigación sobre la calidad del agua del Río Reconquista se inscribe en un problema ambiental, social y tecnológico de alta relevancia y urgencia. La degradación sostenida de uno de los ríos más contaminados de Argentina plantea desafíos concretos tanto para la salud de las comunidades ribereñas como para la preservación de los ecosistemas acuáticos de la región metropolitana de Buenos Aires.

La propuesta metodológica central —generar datos sintéticos de alta calidad para acelerar el entrenamiento de modelos de inteligencia artificial— responde de manera innovadora y pragmática a las limitaciones reales del proyecto: escasos recursos económicos, compleja logística de muestreo y ausencia de infraestructura de monitoreo automático.

Los resultados obtenidos con ambas técnicas de generación de datos sintéticos —Simulación de Montecarlo con transformación Box-Cox (88.77%) y Variational Autoencoder (89.26%)— demuestran que es posible alcanzar un nivel de similitud con los datos reales suficiente para avanzar con análisis estadísticos robustos y el entrenamiento de modelos de machine learning.

La complementariedad de ambos métodos es uno de los hallazgos más relevantes del trabajo: Montecarlo es superior cuando el dataset real es pequeño y cuando se busca reproducir con fidelidad las distribuciones marginales de cada variable; mientras que el VAE es superior para capturar relaciones complejas y no lineales entre múltiples variables, lo cual resulta fundamental para preservar la estructura correlacional de los parámetros del agua.

En un contexto más amplio, el enfoque adoptado contribuye al campo de la ciencia de datos aplicada a la gestión ambiental, demostrando que la combinación inteligente de métodos estadísticos clásicos y técnicas de inteligencia artificial puede superar las limitaciones de proyectos con recursos escasos y abrir caminos para una gestión más eficiente y fundamentada de los recursos hídricos.

«La generación de datos sintéticos no solo resuelve un problema técnico relacionado con la falta de datos, sino que también contribuye significativamente a la viabilidad y éxito del proyecto en su conjunto.»

— Marcelo Fabián Esperanza, 2024