Contrastación de Métodos de Simulación para Ampliar Evidencias con Vistas a Desarrollar un Proceso de Minería de Datos (Un Testigo Basado en los parámetros del Índice de Calidad del Agua)

Carlos Gustavo Lopez[1], Enrique Fernandez[1], Marcelo Fabián Esperanza[1], Martin Pastorini[1], Natanael Ferrán[1], María Alejandra Ochoa[1]

[1] Universidad Nacional del Oeste,
gustavolopez/ enfernandez/ mpastorini/ nferran/ mochoa@uno.edu.ar,
maresperanza9@hotmail.com

Resumen. En el presente trabajo se compara el desempeño de distintos métodos de simulación (estadísticos y basados en redes neuronales) con el fin de determinar cuál es el más apropiado para recrear el comportamiento de las variables utilizadas en el cálculo de calidad del agua.

Palabras Clave: Simulación de Montecarlo, Simulación basada en IA, Minería de Datos, Ampliación de Evidencia, Generador de Datos Aleatorio.

1 Introducción

Es conocido que para poder realizar procesos de explotación de información los dataset deben ser estadísticamente confiables, para lo cual, entre otras cosas, es necesario contar con gran cantidad de datos. Cuantos más datos se tengan, mayor será la probabilidad de que reflejen con precisión la realidad y obtener conclusiones significativas y robustas. La ley de los grandes números establece que, a medida que aumenta el tamaño de una muestra, las estimaciones estadísticas tienden a ser más precisas y estables [1].

Desde el Instituto de Ingenierías y Nuevas tecnologías de la Universidad Nacional del Oeste se está llevando adelante un proyecto de investigación que tiene como objetivo analizar las propiedades del agua del Río de la Reconquista con el objetivo de poder predecir en el futuro posibles focos de contaminación o cambios llamativos en la composición del agua [2, 3]. En este contexto, por la propia naturaleza del actual proyecto, resulta costosa y lenta la recolección de datos, por ello se realizó un proceso de simulación de datos con el fin de ampliar el nivel de evidencia y comenzar a ensayar con técnicas de minería.

Con referencia a lo antes mencionado el método de Montecarlo constituye una técnica fundamental en el campo de la simulación y la modelización computacional.

La simulación de Montecarlo es un tipo de simulación estocástica que permite obtener resultados aproximados en situaciones complejas. Un modelo es estocástico cuando al menos una variable del mismo es tomada como un dato al azar y las relaciones entre variables se toman por medio de funciones probabilísticas.

El método en cuestión se basa en la generación de múltiples muestras aleatorias para estimar soluciones a problemas complejos que pueden ser difíciles o imposibles de resolver mediante métodos analíticos tradicionales [4].

Una de las principales ventajas del método de Montecarlo es su versatilidad y aplicabilidad a una amplia gama de problemas. Puede utilizarse para modelar sistemas complejos y estocásticos, donde las variables pueden seguir distribuciones de probabilidad específicas o donde hay una gran cantidad de incertidumbre. Esto lo convierte en una herramienta poderosa para abordar problemas del mundo real, donde las condiciones pueden ser dinámicas y no lineales [5].

Además, el método de Montecarlo permite evaluar el comportamiento de sistemas complejos bajo diferentes escenarios y condiciones, lo que facilita la toma de decisiones informadas en situaciones de incertidumbre [6].

El proceso de simulación consiste en calcular las medias y desviaciones estándar de cada componente a simular a partir de las muestras generadas. Posteriormente, estos estadísticos se emplean como parámetros para ajustar una distribución de probabilidad. Existen varias alternativas de simulación de este tipo entre las cuales resaltamos [7, 8]:

- Simulación por defecto
- Truncar en valores máximos y mínimos
- Truncar en Cero
- Distribuciones No Negativas
- Re-simulación
- Transformación de Datos

Como alternativa al método de Montecarlo existen los Autoencoders , los cuales son un tipo de red neuronal utilizada para el aprendizaje no supervisado. Este tipo de red no solo aprende a codificar y decodificar datos, sino que también aprende la distribución de los datos, permitiendo la generación de nuevos ejemplos y mejorando la capacidad de generalización del modelo [8]. Existen dos versiones de este tipo de algoritmo:

- Autoencoder básico
- Autoencoder variacional.

El desafío en este punto es identificar cuál de las distintas variantes de simulación existentes es la que mejor se ajusta al contexto del problema, donde se cuenta con 280 muestras compuestas de 12 variables definidas para analizar la calidad del agua del río de la Reconquista, para las cuales los valores generados deben respeten una distribución normal ya que es la que mejor ajusta a los fenómenos naturales [10].

En los siguientes apartados se describe en que consiste cada una de estas técnicas y se debate sobre los resultados obtenidos.

2 Estado de la Cuestión

2.1 Trabajo de Campo

El proyecto "Elaboración de un modelo para la determinación del Índice de Calidad del Agua (ICA) en aguas superficiales de la cuenca alta del río Reconquista en el partido de Merlo con desarrollo e implementación de una herramienta de Inteligencia Artificial" que lleva adelante el Instituto de Ingenierías y Nuevas Tecnologías de la Universidad Nacional del Oeste, busca desarrollar un modelo predictivo del comportamiento del agua del Río de la Reconquista. Para ello se realizan tareas de muestreo y análisis químico de las propiedades del agua en cinco puntos del Rio, todos vinculados a su paso por el Partido de Merlo. Con los datos relevados se planea desarrollar, entre otras cosas, procesos de análisis y minería de datos para comprender cómo es la composición del agua y cómo es su evolución a lo largo del año. Con estos datos se pretende detectar de manera rápida la aparición de anomalías que comprometan la calidad del agua [1].

La tarea de recolección y análisis de muestras es un proceso lento y costoso. Actualmente se muestrea dos veces por semana durante el proceso lectivo, generando hasta el momento 280 muestras basadas en variables de contexto climático y propias del fenómeno biológico, las cuales se detallan a continuación:

1. Temperatura ambiental (TA)
2. Humedad
3. Temperatura de la muestra (TM)
4. Alcalinidad del Agua (PH)
5. Conductividad Eléctrica (CE)
6. Sólidos Totales Disueltos (STD)
7. Sólidos Totales en Suspensión (STS)
8. Oxígeno disuelto (OD)
9. Nivel del agua (NA)
10. Turbidez
11. Dureza
12. Cloruros

Por temas de espacio no se presentan en este documento los valores obtenidos, pero con gusto podemos facilitarlos si nos lo solicitan al mail de la referencia.

2.2 Técnicas de simulación estadísticas

A continuación, se describe en qué consiste cada uno de los métodos de simulación estadísticos utilizados [7, 8]:

- Simulación por defecto: Se generan valores aleatorios dentro de los límites definidos, pero no se realiza validación alguna sobre los valores arrojados por el simulador. Se corre el riesgo de dar por válidos ensayos cuyos valores no existirían en la realidad.
- Truncar en valores máximos y mínimos: Se generan valores aleatorios dentro de los limites definidos. Cualquier valor generado fuera del rango es truncado al valor máximo o mínimo según corresponda.

- Truncar en Cero: Se generan valores aleatorios dentro de los límites definidos. Cualquier valor negativo se convierte en cero. Es el enfoque más simple, pero puede introducir sesgo en las simulaciones.
- Distribuciones No Negativas: Utiliza una distribución de probabilidad que solo genere valores no negativos. Se intenta con una distribución log-normal, una distribución exponencial y una distribución gamma.
- Re-simulación: Se generan valores aleatorios dentro de los límites definidos. Cada vez que se obtiene un valor fuera de rango, se vuelve a simular hasta obtener un valor válido. Puede ser computacionalmente intensivo si hay muchas re-simulaciones.
- Transformación de Datos: En ocasiones una transformación (como tomar el logaritmo) hace que los datos se ajusten mejor a una distribución normal. Luego se puede aplicar la transformación inversa a los datos simulados. Se utilizan la transformación de Box-Cox y la de Yeo-Johnson.

2.3 Técnicas de simulación basadas en Redes Neuronales

Un autoencoder es un tipo de red neuronal utilizada principalmente para aprender representaciones eficientes de los datos, típicamente para reducción de dimensionalidad o para la compresión de datos. Consiste en dos partes principales:

1. Codificador (Encoder): Este parte toma los datos de entrada y los transforma en una representación de menor dimensión. La codificación captura las características esenciales de los datos originales.
2. Decodificador (Decoder): Esta parte toma la representación codificada y trata de reconstruir los datos originales a partir de ella.

El objetivo del autoencoder es que la salida del decodificador sea lo más cercana posible a la entrada original. Para lograr esto, se entrena la red neuronal minimizando la diferencia (o pérdida) entre la entrada y la salida reconstruida. Los autoencoders se utilizan en diversas aplicaciones como reducción de ruido en imágenes y generación de datos sintéticos.

Existen dos variantes del autoencoder: el básico y el variacional. La diferencia principal radica en que mientras que el autoencoder básico se centra en la compresión y reconstrucción de los datos, el autoencoder variacional tiene un enfoque más probabilístico, buscando aprender una distribución latente que permita no solo la reconstrucción sino también la generación de nuevos datos.

Un autoencoder variacional no solo aprende a mapear los datos a un espacio latente y a reconstruirlos, sino que también trata de hacer que la distribución de esos puntos en el espacio latente siga una distribución normal multivariada, típicamente con media cero y varianza unitaria [8].

3 Definición del Problema

Si bien se logró identificar una buena cantidad de métodos de simulación, no se sabe a ciencia cierta cuál de ellos se ajusta mejor a la generación de datos sintéticos que imiten las propiedades y características de los datos reales obtenidos del Río de la Reconquista. Estos datos sintéticos o artificiales se podrán utilizar luego para diversas

aplicaciones, incluyendo el entrenamiento de modelos de aprendizaje automático y minería de datos.

4 Solución Propuesta

Desarrollar un software “banco de pruebas” bajo la siguiente premisa:

- Generar 10.000 simulaciones de las 12 variables consideradas para la estimación del índice de calidad del agua tomando como base las 280 muestras actuales. El objetivo es que estas muestras permitan identificar cotas máximas y mínimas para cada variable con el fin de prescindir de los valores teóricos que pueden o no ajustar a la realidad del Río de la Reconquista.

5 Resultados Obtenidos

A continuación, se presentan los histogramas de frecuencia obtenidos con cada una de las técnicas y la interpretación de dichos resultados:

Simulación por defecto: Como se observa en la figura 1, los valores generados por este método se ajustan perfectamente a una distribución normal, pero en varios casos arrojaban valores inapropiados (por ejemplo, la variable Humedad muestra valores negativos). Por este motivo se considera que el método no es adecuado para el problema actual.

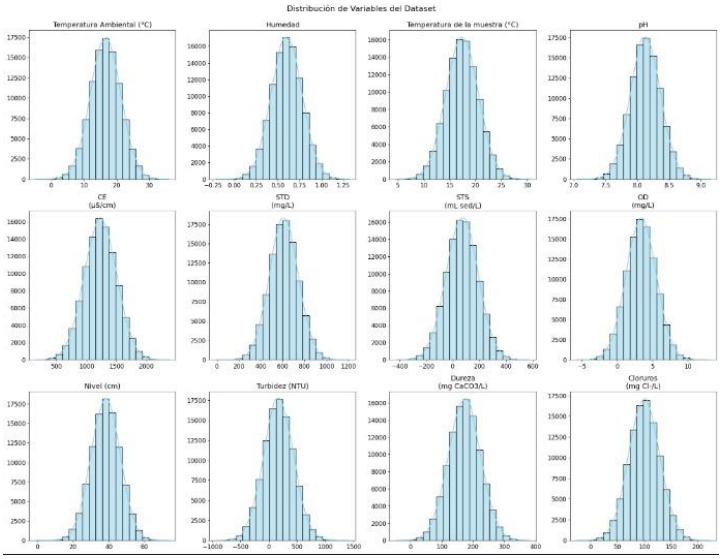

Figura 1: distribución de probabilidad Simulación por defecto

Truncar en valores máximos y mínimos: Como se observa en la figura 2, si bien con esta técnica los valores generados fueron válidos, la distribución de probabilidades dejó de corresponderse con una distribución normal (ver variable

STS). Por este motivo se considera que el método no es adecuado para el problema actual.

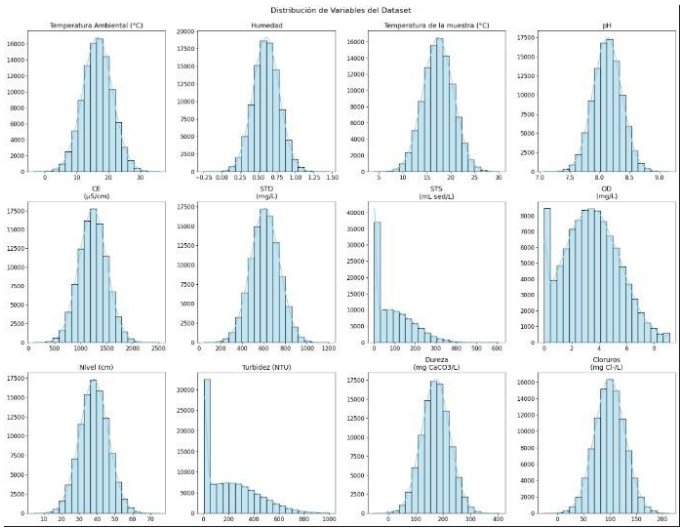

Figura 2: distribución de probabilidad Truncar Valores Máximos y Mínimos

Truncar en Cero: Como se observa en la figura 3, si bien los valores generados fueron válidos, la distribución de probabilidades dejó de corresponderse con una distribución normal (ver variable STS). Por este motivo se considera que el método no es adecuado para el problema actual.

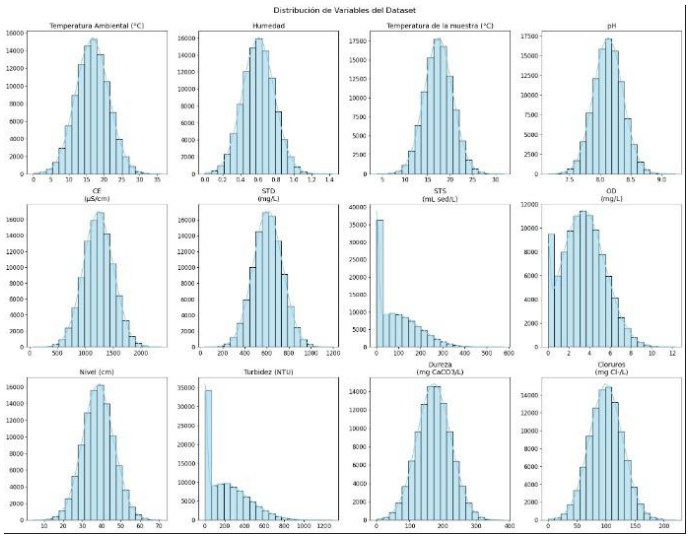

Figura 3: distribución de probabilidad Truncar a Cero

Distribuciones No Negativas: Como se observa en la figura 4, si bien los valores generados fueron válidos, la distribución de probabilidades a nivel general dejó de corresponderse con una distribución normal. Por este motivo se considera que el método no es adecuado para el problema actual.

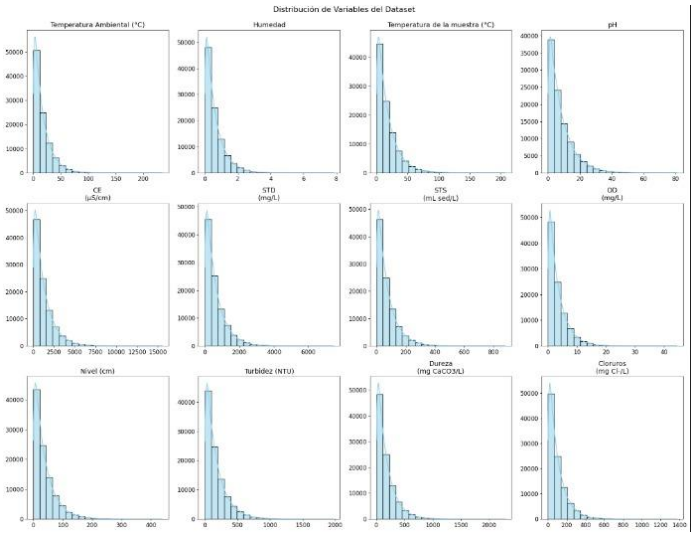

Figura 4: distribución de probabilidad Distribuciones no Negativas

Re-simulación: Como se observa en la figura 5, para esta técnica los valores generados fueron válidos, pero la gráfica muestra una asimetría a izquierda en algunos casos (ver variable STD). Mas allá de este defecto los histogramas parecen ser adecuados.

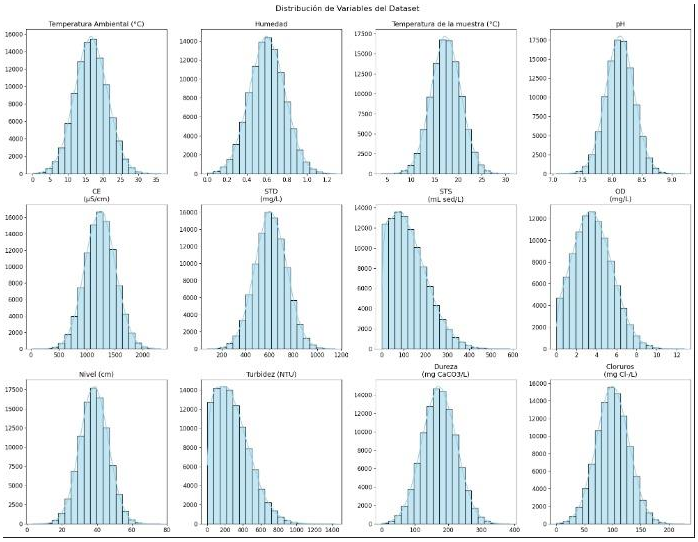

Figura 5: distribución de probabilidad Re-Simulación

Transformación de Datos: Como se observa en la figura 6, si bien con esta técnica los valores generados fueron válidos, la distribución de probabilidades dejó de corresponderse con una distribución normal (ver variable STD). Por este motivo se considera que el método no es adecuado para el problema actual.

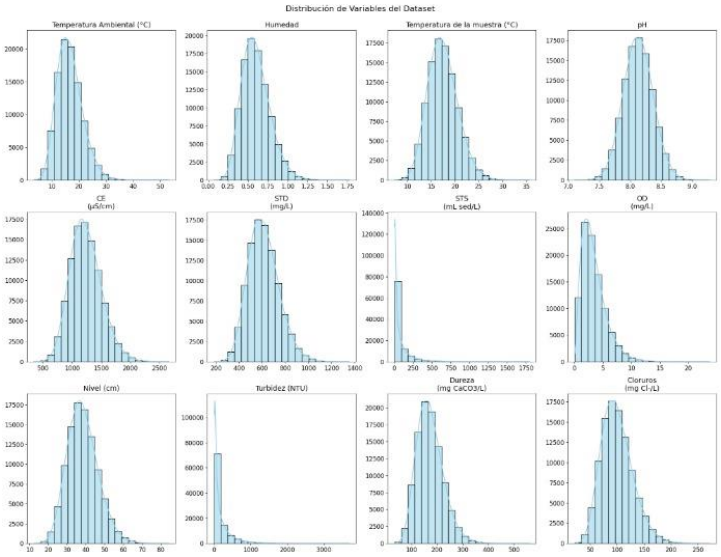

Figura 6: distribución de probabilidad Transformación de datos

Autoencoder básico: Como se observa en la figura 7, si bien con esta técnica los valores generados fueron válidos, la distribución de probabilidades dejó de corresponderse con una distribución normal. Por este motivo se considera que el método no es adecuado para el problema actual.

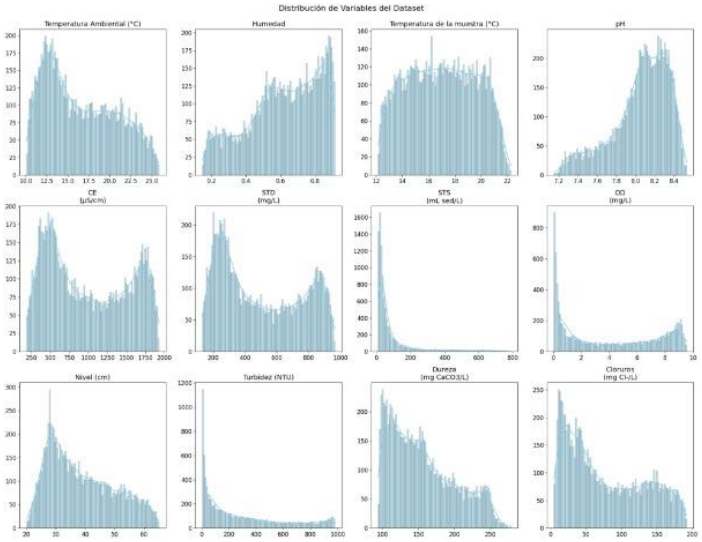

Figura 7: distribución de probabilidad Autoemncoder Básico

Autoencoder variacional: Como se observa en la figura 8, si bien con esta técnica los valores generados fueron válidos, la distribución de probabilidades dejó de corresponderse con una distribución normal. Por este motivo se considera que el método no es adecuado para el problema actual.

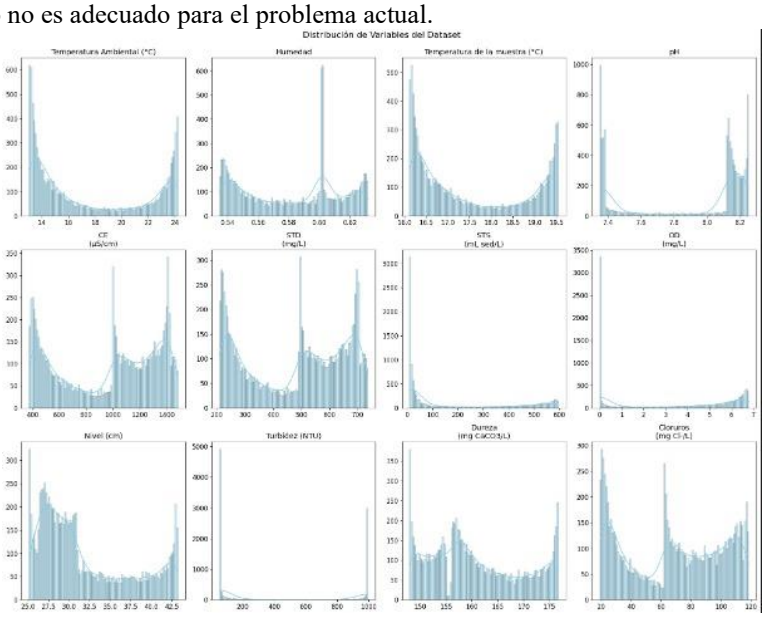

Figura 8: distribución de probabilidad Autoencoder Variacional

6 Conclusión

Después de un exhaustivo análisis del proceso de simulación llevado a cabo, llegamos a la conclusión de que ninguno de los métodos evaluados se ajusta de manera óptima a las necesidades del problema. En tal sentido recomendamos el uso de la técnica de re-simulación, que, a pesar de mostrar sesgo en tres variables por un problema de asimetría, el conjunto de datos generado en general es válido y adecuado para iniciar los procesos de minería de datos con el objetivo de identificar patrones de comportamiento iniciales.

Es importante destacar también que, si bien las técnicas basadas en redes neuronales obtuvieron valores válidos en todos los casos, la distribución de valores quedó pegada a la distribución de la muestra. Esto puede ser de gran ayuda cuando el set de entrenamiento es significativo y respeta la forma de distribución de la población, lo cual no ocurrió en el caso que nos ocupa. Por otro lado, algunas de las técnicas basadas en procesos estadísticos mostraron ser más robustas a este problema ya que los números se generan en base a una semilla que cumple con la forma de la distribución independientemente de la muestra

5 Futuras Líneas de Investigación

Si bien se logró identificar un método que logró ajustar los valores simulados a la distribución deseada, en el presente trabajo no se tomó como restricción establecer posibles relaciones entre las variables, por ejemplo, la relación que pudiese existir entre la temperatura y el oxígeno disuelto en el agua, en los siguientes trabajos analizaremos cómo es el comportamiento de los métodos respecto de esta nueva restricción.

8 Bibliografía

[1] Richard I. Levin y David S. Rubin ; "Estadística para Administración y Economía" (2003)

[2] Carlos Lopez, Enrique Fernandez, Natanael Ferrán, Martín Pastorini, Nicolás Coronel, Marcelo Esperanza: "Análisis del Río de la Reconquista"; Ingeniería Sanitaria y Ambiental, Nro. 149; ISSN 0328 2937 (octubre 2023)

[3] Carlos Lopez, Enrique Fernandez, Marcelo Esperanza, Martín Pastorini, Natanael Ferrán: "Simulador de Ensayos de Laboratorio para Análisis de Calidad del Agua"; XXVI Workshop Investigadores en Ciencias de la Computación (abril 2023)

[4] García-Pérez, M. A.: "Introducción a la Simulación Estocástica" ; Editorial Reverté (2009)

[5] Dieste, O., Fernández, E., García-Martínez, R., Juristo: "Comparative Analysis of Meta-Analysis Methods: When to use Which?"; Proceedings 15th Annual Conference on Evaluation & Assessment in Soft-ware Engineering (EASE) (2011).

[6] Gilks, W., Richardson, S. & Spiegel-halter, D. Markov Chain Monte Carlo in Practice, Chapman & Hall, London

[7] Amsterdam, H.F.: "The use of Monte Carlo Simulation to quantify the uncertainty in modeled estimates of toxic, radiation and overpressure impacts resulting from accidets in large chemical plants". Master thesis. Peninsula Technikon (2004).

[8] Pardoux, Introduction to Monte Carlo methods for transport and diffusion equations

[9] Kingma, D. P., & Welling, M.: "Auto-Encoding Variational Bayes". arXiv preprint arXiv:1312.6114 (2014).

[10] Rodríguez Alonso Juan José: "Estadística básica para técnicas de laboratorio". Createspace Independent Publishing Platform (2011)