INFORME

1ER PARCIAL

EXPLOTACIÓN DE DATOS

Juan Pablo Frascino

1)

Comienzo a realizar el analisis univariado, para esto realizo un summary y luego el grafico de boxplot y obtengo lo siguiente:

```
    retenc           edad          empleo           propia           otras
Min.   : 1.00   Min.   : 2.0   Min.   :-21.00   Min.   : 0.000   Min.   : 0.000
1st Qu.:17.00   1st Qu.:32.0   1st Qu.:  3.00   1st Qu.: 4.101   1st Qu.: 3.134
Median :34.00   Median :40.0   Median :  8.00   Median :10.576   Median :10.992
Mean   :35.51   Mean   :41.6   Mean   : 10.93   Mean   :13.093   Mean   :13.859
3rd Qu.:54.00   3rd Qu.:51.0   3rd Qu.: 17.00   3rd Qu.:19.890   3rd Qu.:20.334
Max.   :72.00   Max.   :77.0   Max.   : 47.00   Max.   :59.058   Max.   :90.205
   ingresos
Min.   :  90.76
1st Qu.: 374.46
Median : 594.22
Mean   : 795.25
3rd Qu.:1014.07
Max.   :5426.37
```

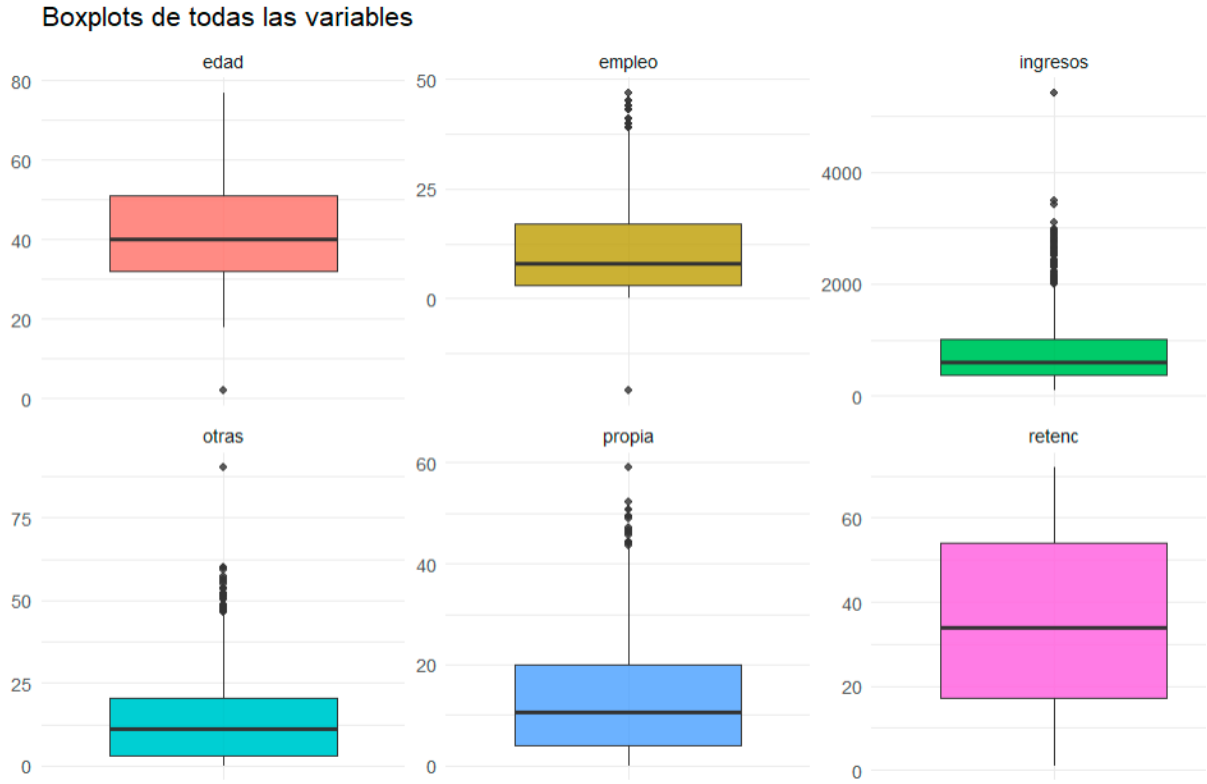

A simple vista resaltan algunos datos anomalos, primero el que se encuentra en “ingresos”, el cual es un valor mucho mas alto que el resto, lo mismo sucede en la variable “otras”, tambien tenemos un dato ligeramente mas alto que lo normal en la variable “propia”. Y finalmente podemos ver en el summary de empleo que hay un dato negativo.

Asi que me fijo cuales son estos datos:

```
> which(datos$ingresos>4000)
[1] 1
> which(datos$otras>75)
[1] 1
```

Para los datos anomalos de “ingresos” y “otras” podemos visualizar que es el mismo caso:

retenc	edad	empleo	propia	otras	ingresos
72	66	41	49.3820074	90.2052072	5426.37343

Volvamos a analizar los datos de las variables “otras” e “ingreso” para ver la anomalia:

```
     otras          ingresos
Min.   : 0.000  Min.   :  90.76
1st Qu.: 3.134  1st Qu.: 374.46
Median :10.992  Median : 594.22
Mean   :13.859  Mean   : 795.25
3rd Qu.:20.334  3rd Qu.:1014.07
Max.   :90.205  Max.   :5426.37
```

Como podemos ver, los valores de este caso se alejan demasiado del resto de datos, esto podria ser problemático para nuestro modelo, se deberia consultar con un experto si estos datos son correctos(que lo podrian ser, debido a que puede ser una persona con mucho ingreso que lo gaste e multiples plataformas) o un error de carga, no obstante en este caso, yo decido eliminarlo debido a que al estar tan alejado del resto, podria sesgar mis resultados.

Luego decido investigar la otra variable que resaltaba en mis boxplot, donde habia un caso donde “propia” era mayor que el resto de datos.

```
> which(datos$propia>55)
[1] 7
```

7	72	75	44	59.0581182	24.1269239	1055.93653

Por mas que el valor de 59 es alto dentro de mi dataset, el resto de datos no se ven anomalos y ademas no esta extramadamente alejado del resto de datos como podemos ver en el boxplot:

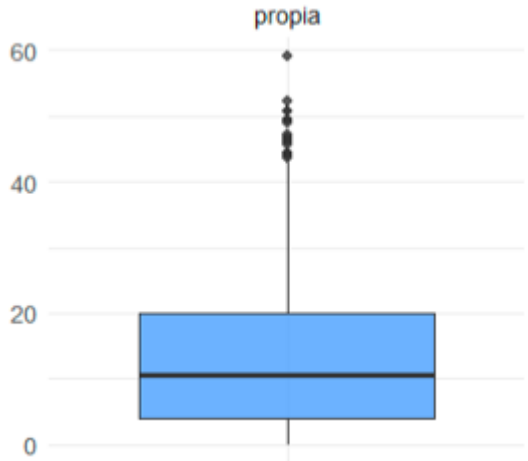

Por lo que no pareciera pudiera a llegar a afectar o sesgar los resultados. Decido dejarlo.

Finalmente reviso ese dato negativo en la variable “empleo”:

```
> which(datos$empleo<0)
[1] 426
```

Vemos que es el unico dato menor a cero en todo el dataset, esto posiblemente sea un error de carga, por lo que decido eliminarlo.

2)

Para desarrollar un modelo que me permita predecir la variable ingreso, lo primero que hago es calcular las correlaciones para poder elegir la variable que mejor me permita predecirlo:

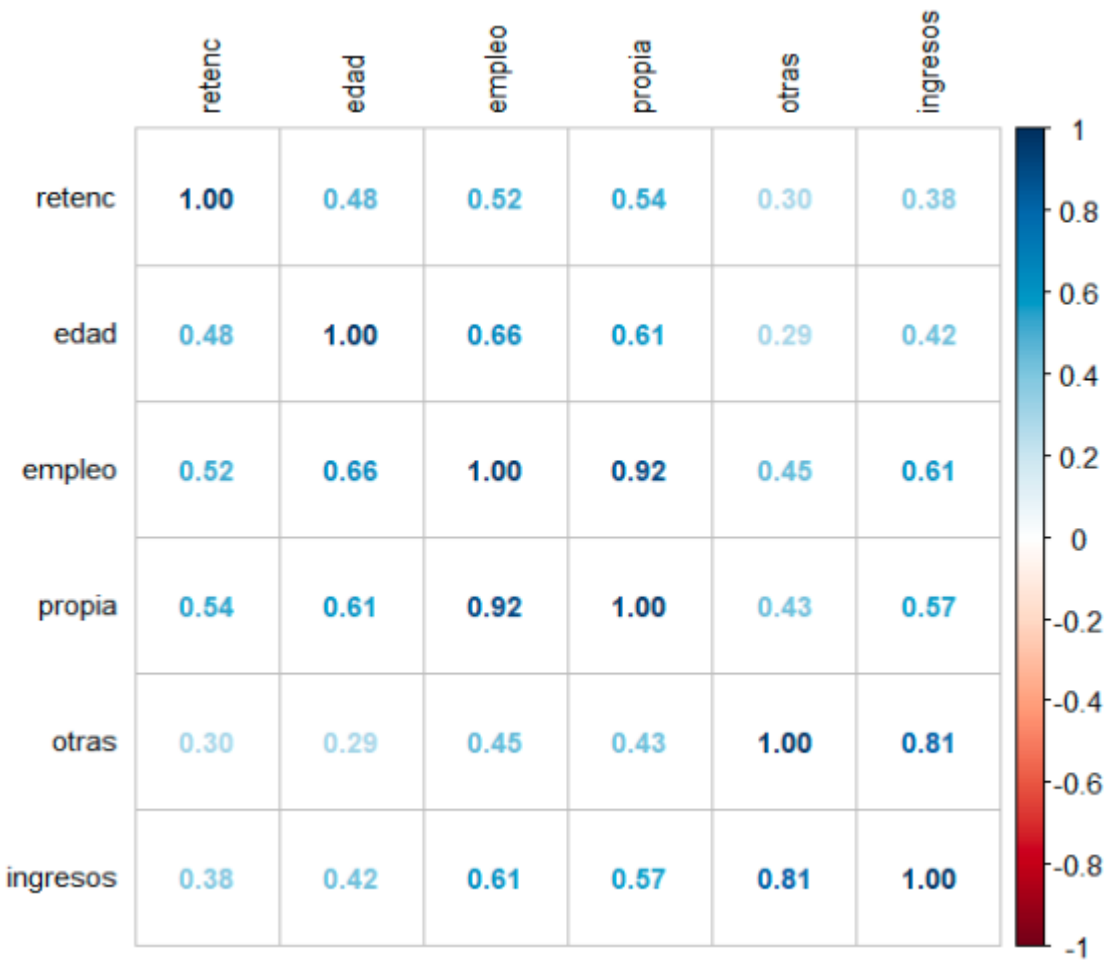

Como podemos ver en la figura de arriba, con mayor correlacion a “ingresos” es “otras”, Por lo que realizo un modelo con “ingresos” como variable indepediente y “otras” como regresor, dandome el siguiente resultado:

```
lm(formula = ingresos ~ otras, data = datos)

Residuals:
    Min      1Q  Median      3Q     Max 
-936.40 -214.90  -33.05  173.78 1451.94 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 269.9392    16.1738   16.69   <2e-16 ***
otras        37.7656     0.8559   44.12   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 349.2 on 995 degrees of freedom
Multiple R-squared:  0.6618,	Adjusted R-squared:  0.6614 
F-statistic:  1947 on 1 and 995 DF,  p-value: < 2.2e-16
```

a)
La ecuacion resultante es:

^
Ingresos=269.93+37.76*otras

La interpretacion seria que, por cada unidad de “otras” que aumente, “ingresos” aumentara en promedio 37.75.

A su vez, podemos ver que el p-valor nos da < 2.2e-16, lo que es extremadamente chico, por lo cual podemos rechazar h0, y por lo tanto el modelo es significativo.

b)
El grafico de la recta ajustada nos quedaria:

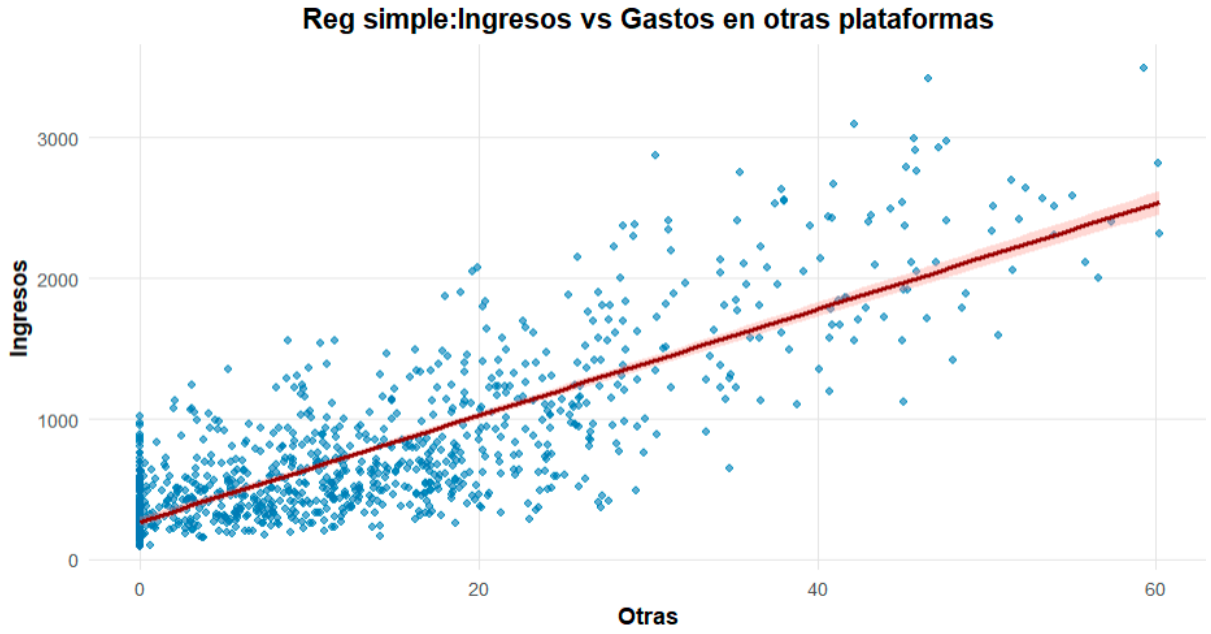

3)
Ahora desarrollemos un modelo que relacione la variable ingreso con todas las variables disponibles:

```
lm(formula = ingresos ~ ., data = datos)

Residuals:
    Min      1Q  Median      3Q     Max 
-866.19 -174.94  -18.18  143.21 1373.98 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  99.3587    37.3154   2.663  0.00788 ** 
retenc        0.7674     0.5551   1.383  0.16713    
edad          1.3776     1.0545   1.306  0.19175    
empleo       20.9270     2.5783   8.117 1.41e-15 ***
propia       -4.0584     2.1790  -1.862  0.06284 .  
otras        31.2595     0.8411  37.166  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 305.5 on 991 degrees of freedom
Multiple R-squared:  0.7422,	Adjusted R-squared:  0.7409 
F-statistic: 570.5 on 5 and 991 DF,  p-value: < 2.2e-16
```

a)

El pvalor nos da < 2.2e-16, lo cual es extremadamente bajo, por lo que podemos volver a rechazar h0, y decir que el modelo es significativo.

b)

La variable mas significativa es “otras”, debido a que tiene el pvalor mas bajo(< 2e-16) y la variable menos significativa es “edad”, debido a que tiene el pvalor mas alto(0.19175)

c)

Finalmente para analizar los puntos significativos calculamos el grafico de la distancia de cook:

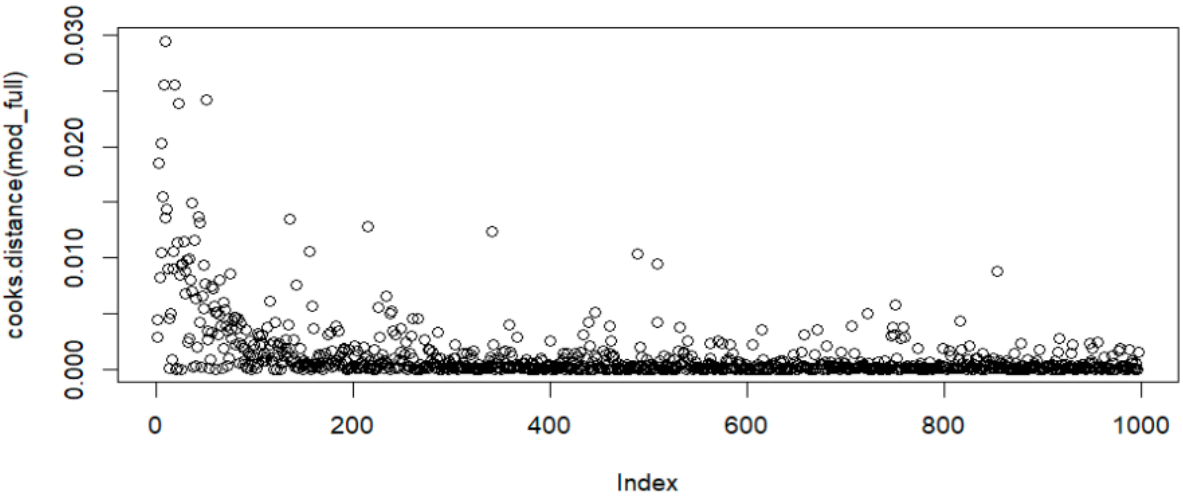

No se observa ningún dato extremadamente alejado del resto, además están todos debajo de uns distancia muy pequeña, menos que 0.03. Por lo que podemos decir que no hay existencia de puntos influyentes.

4)
Ahora me pide hacer 3 modelos:
- Un modelo con todas las variables disponibles.
- El modelo con las 2 variables más significativas del modelo completo.
- Un modelo obtenido por selección automática por pasos.

El primer modelo ya lo tengo, es el mod_full utilizado en el punto anterior.

El segundo modelo decido crearlo con las variables “otras” y “empleo”, ya que al analizar el modelo completo me dieron que eran las mas significativas con un pvalor de < 2e-16 en “otras” y de 1.41e-15 en “empleo”.

Y por tercero un modelo realizado por selección automática de pasos, para esto utilice los 3 metodos(“forward”, “backward” y “both)

A partir de la creación de estos modelos realice las comparaciones:

```
> comparacion
         Modelo      R2Aj      AIC
1       modFull 0.7408514 14246.82
2 mod2Variables 0.7397275 14248.15
3        modFor 0.7408514 14246.82
4       modBack 0.7406669 14246.54
5       modBoth 0.7406669 14246.54
```

Podemos observar como los modelos Full y el realizado por el método Forward son los que tiene mayor r2 ajustado(siendo el mismo modelo ambos), pero los modelos realizados por los métodos Backward y Both tienen menor AIC(siendo ambos el mismo modelo), las diferencias tanto en r2 adj como AIC son minimas, por lo que veamos mas a detalle los summary de los modelos para elegir:
SUMMARY DEL MODSTEP_FOR(MISMO QUE EL FULL):

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  99.3587    37.3154   2.663  0.00788 **
retenc        0.7674     0.5551   1.383  0.16713
edad          1.3776     1.0545   1.306  0.19175
empleo       20.9270     2.5783   8.117 1.41e-15 ***
propia       -4.0584     2.1790  -1.862  0.06284 .
otras        31.2595     0.8411  37.166  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 305.5 on 991 degrees of freedom
Multiple R-squared:  0.7422,	Adjusted R-squared:  0.7409
F-statistic: 570.5 on 5 and 991 DF,  p-value: < 2.2e-16
```

SUMMARY DEL MODSTEP_BACK(MISMO QUE EL BOTH):

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 140.7607    19.7037   7.144 1.75e-12 ***
retenc        0.9285     0.5414   1.715   0.0867 .
empleo       22.0333     2.4361   9.044  < 2e-16 ***
propia       -4.1786     2.1779  -1.919   0.0553 .
otras        31.2329     0.8411  37.132  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 305.6 on 992 degrees of freedom
Multiple R-squared:  0.7417,    Adjusted R-squared:  0.7407
F-statistic: 712.2 on 4 and 992 DF,  p-value: < 2.2e-16
```

Se puede observar como el r2 ajustado tan solo varia en 0.0002 del modelo FOR al modelo BACK, pero el modelo BACK tiene un regresor menos, por que termino eligiendo este. Pero antes verifico que no tenga Multicolinealidad:

```
> vif(modStep_back)
  retenc   empleo   propia    otras
1.423437 6.373192 6.447868 1.260789
```

No la tiene, perfecto.

Eligiendo el modelo BACK(“modStep_Back”), analicemos los supuestos:

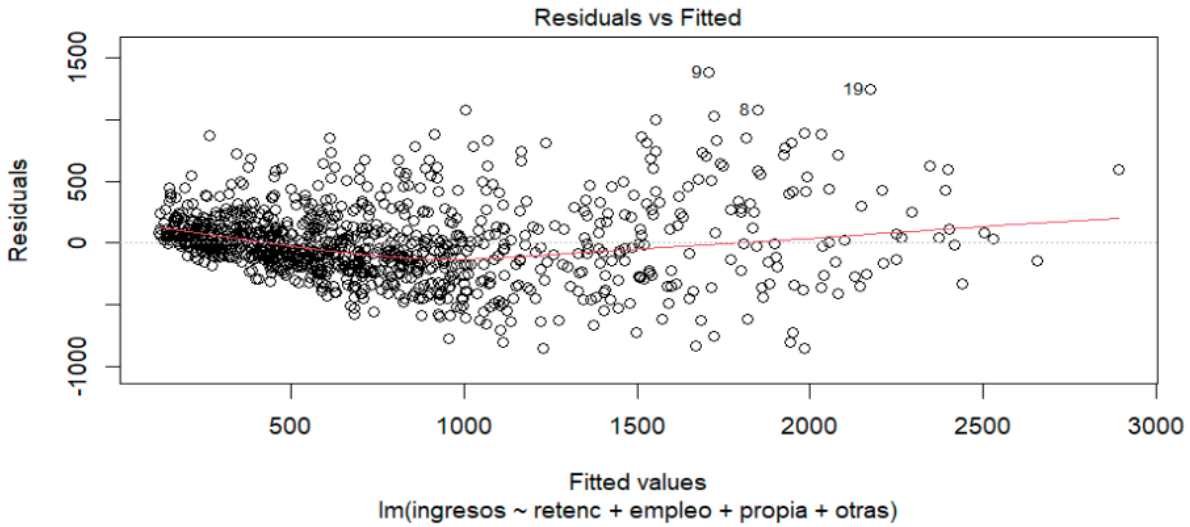

Podemos analizar 2 cosas en este grafico(Residual vs FItted):

Primero, los residuales no se encuentran tan cercano al cero, podemos ver como varían de un rango -1000 a 1000, alejándose de cero.

Segundo, la homogeneidad en la varianza no se cumple de manera perfecta, podemos observar un ligero patrón que marca una tendencia a formar un cono(los datos al inicio están mas agrupados y luego se va dispersando abriéndose)

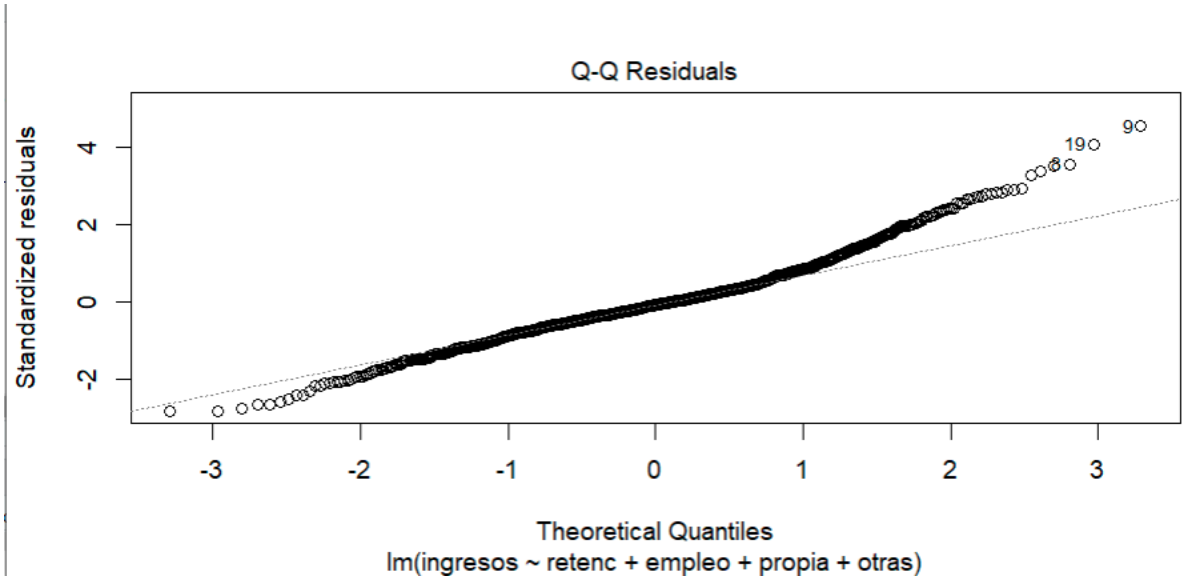

Finalmente en el segundo grafico(QQ residuales), podemos observar que no hay normalidad en los errores debido a que los puntos no siguen la línea uniformemente, por lo que no respetan la distribución normal.

PREDICCION:

Retenc= 54	Edad= 68	Empleo=27	Propia= 24,41	Otras= 28,56

Para terminar vamos a realizar una predicción de ingreso a partir de los datos de la figura de arriba y el modelo seleccionado:

```
> datos_prediccion<-data.frame(retenc=54, edad=68, empleo=27, propia=24.21, otras=28.56)
> predict(modStep_back, datos_prediccion)
       1
1576.645
```

El modelo elegido predice que para una persona con las variables mencionadas, su ingreso seria de 1576.

Vuelvo a revisar mis datos para verificar que sea un resultado razonable:

```
    ingresos
 Min.   :  90.76
 1st Qu.: 374.45
 Median : 594.17
 Mean   : 790.70
 3rd Qu.:1013.51
 Max.   :3492.53
```

Como vemos, 1576 se encuentra entre el rango minimo y máximo de la variable, por lo que es un resultado posible.