Simulador de Ensayos de Laboratorio para Análisis de Calidad del Agua

Carlos Gustavo Lopez, Enrique Fernandez, Marcelo Fabián Esperanza, Martin Pastorini, Natanael Ferrán

Universidad Nacional del Oeste

gustavolopez/ enfernandez/ mpastorini/ nferran@uno.edu.ar, maresperanza9@hotmail.com

Resumen

El objeto del siguiente trabajo es presentar, validar y cotejar entre sí múltiples estrategias de simulación con la finalidad de ampliar las muestras obtenidas de las componentes del agua del Rio de la Reconquista y de esta forma contar de manera temprana con la cantidad de datos necesaria poder procesarlos, explorarlos, descubrir patrones y obtener relaciones.
Estos algoritmos se diseñan con la capacidad de ser fácilmente adaptados a diversas situaciones, lo que permite probar diferentes técnicas y enfoques para determinar cuál de ellos se ajusta mejor a las necesidades específicas del problema en cuestión.

Palabras clave: Simulación de Montecarlo, Minería de Datos, Ampliación de Evidencia, Generador de Datos Aleatorio

Contexto

El proyecto "Elaboración de un modelo para la determinación del Índice de Calidad del Agua (ICA) en aguas superficiales de la cuenca alta del río Reconquista en el partido de Merlo con desarrollo e implementación de una herramienta de Inteligencia Artificial" que lleva a delante el Instituto de Ingeniería y Nuevas Tecnologías de la Universidad Nacional del Oeste, busca desarrollar un modelo predictivo del comportamiento del agua del Rio de la Reconquista. Para ello se realizan tareas de muestreo y análisis químico de las propiedades del agua en cinco puntos del Rio, todos vinculados a su paso por el Partido de Merlo. Con los datos relevados se planea desarrollar, entre otras cosas, procesos de análisis y minería de datos para comprender como es la composición del agua y como es su evolución a lo largo del año. Con estos datos se pretende detectar de manera rápidamente la aparición de anomalías que comprometan la calidad del agua [1].
La tarea de recolección y análisis de muestras es un proceso lento y costoso. Por temas de logística y capacidad de análisis actualmente se recolectan y analizan dos muestras de agua semanales. A este ritmo obtener un dataset fiable para realizar trabajos análisis planificados tomaría varios años. Por tal motivo se decidió llevar adelante un proceso de simulación de Montecarlo, basado en los datos recolectados en el año 2023, que permita generar un dataset de mayor volumen para poder probar y validar tempranamente los procesos de minería de datos que mejor se ajusten al fenómeno sobre el cual se está trabajando.

Introducción

Es conocido que para poder realizar procesos estadísticos confiables es necesario contar con gran cantidad de datos. Cuántos más datos se tengan, mayor será la probabilidad de que reflejen con precisión la realidad y obtener conclusiones significativas y robustas. La ley de los grandes números establece que, a medida que aumenta el tamaño de una muestra, las estimaciones estadísticas tienden a ser más precisas y estables [2].

Como ya se mencionó, por la propia naturaleza del actual proyecto, resulta costosa y lenta la

recolección de datos. Por ello se propone ampliar el nivel de evidencia mediante procesos de simulación, que ayude a extender la masa de datos y de esa forma poder aplicar modelos estadísticos o de IA con mayor nivel de fiabilidad. Cabe destacar que, por su naturaleza, estos procesos de simulación deben ejecutarse varias veces a lo largo de la vida de un proyecto para ir ajustando los niveles de error a medida que las evidencias aumentan.

Con referencia a lo antes mencionado el método de Montecarlo constituye una técnica fundamental en el campo de la simulación y la modelización computacional. Se basa en la generación de múltiples muestras aleatorias para estimar soluciones a problemas complejos que pueden ser difíciles o imposibles de resolver mediante métodos analíticos tradicionales [3].

Una de las principales ventajas del método de Montecarlo es su versatilidad y aplicabilidad a una amplia gama de problemas. Puede utilizarse para modelar sistemas complejos y estocásticos, donde las variables pueden seguir distribuciones de probabilidad específicas o donde hay una gran cantidad de incertidumbre. Esto lo convierte en una herramienta poderosa para abordar problemas del mundo real, donde las condiciones pueden ser dinámicas y no lineales [4].

Además, el método de Montecarlo permite evaluar el comportamiento de sistemas complejos bajo diferentes escenarios y condiciones, lo que facilita la toma de decisiones informadas en situaciones de incertidumbre [5].

El proceso de simulación consiste en calcular las medias y desviaciones estándar de cada componente a simular a partir de las muestras generadas. Posteriormente, estos estadísticos se emplean como parámetros para ajustar una distribución de probabilidad. Mediante la utilización de un generador de números aleatorios y la distribución de probabilidad seleccionada se procede a realizar las simulaciones. A continuación, se describen seis variantes del método [6,7]:

1. *Simulación por defecto*: No se realiza validación alguna sobre los valores arrojados por el simulador. Se corre el riesgo de dar por válidos ensayos cuyos valores no existirían en la realidad.
2. *Truncar en valores máximos y mínimos*: Cualquier valor fuera del rango es truncado a los valores establecidos.
3. *Truncar en Cero*: Cualquier valor negativo se convierte en cero. Es el enfoque más simple, pero puede introducir sesgo en las simulaciones.
4. *Distribuciones No Negativas*: Usar una distribución de probabilidad que solo genere valores no negativos. Se intenta con una distribución log-normal, una distribución exponencial y una distribución gamma.
5. *Re-simulación*: Cada vez que se obtiene un valor negativo, se vuelve a simular hasta obtener un valor positivo. Puede ser computacionalmente intensivo si hay muchas re-simulaciones.
6. *Transformación de Datos*: En ocasiones una transformación (como tomar el logaritmo) hace que los datos se ajusten mejor a una distribución normal. Luego se puede aplicar la transformación inversa a los datos simulados. Se utilizan la transformación de Box-Cox y la de Yeo-Johnson.

Líneas de Investigación y Desarrollo

El análisis de calidad del agua conjuga parámetros físicos, químicos y biológicos, los cuales responden a definiciones teóricas de máximos y mínimos. Ahora bien, estos máximos y mínimos teóricos no son universales, sino que se ajustan a las condiciones climáticas en las cuales se encuentran los ríos [1]. Por ello se realizaron procesos de simulación de 10.000 muestras para cada uno de los métodos de simulación indicados en la introducción y luego se procedió a verificar si los resultados obtenidos

en las simulaciones respondían, primero a los valores definidos por la teoría y luego a si estos valores estaban dentro del rango de la media obtenida en los trabajos de campo y dos desvíos estándar a cada lado de la misma.

Como en todo fenómeno natural los componentes del agua recavados y utilizados para medir la calidad de la misma siguen una distribución de probabilidad normal. Esto también fue validado mediante histogramas de frecuencia en los resultados obtenidos de la simulación.

A continuación, se presenta como fue el comportamiento de los componentes simulados en función a cada uno de los métodos seleccionados para el análisis de la variable "turbidez":

1. *Simulación por defecto*:
   Al realizar la simulación se presentó el inconveniente de que algunos de los datos simulados arrojaban valores inapropiados. Se verificó que dichos datos poseían un desvío estándar elevado y si bien los valores eran correctos conforme a los instrumentos de medición utilizados, presentaban algunos valores atípicos que podrían considerarse outliers. Por este motivo el método fue descartado.
2. *Truncar en valores máximos y mínimos*:
   Si bien con esta técnica los valores generados fueron todos válidos, la distribución de probabilidades dejo de corresponderse con una distribución normal. Por este motivo el método fue descartado. En la figura 2 se muestra la distribución obtenida.
3. *Truncar en Cero*:
   Si bien con esta técnica los valores generados fueron todos válidos, la distribución de probabilidades dejo de corresponderse con una distribución normal. Por este motivo el método fue descartado. En la figura 3 se muestra la distribución obtenida.
4. *Distribuciones No Negativas*:
   Si bien con esta técnica los valores generados fueron todos válidos, no hubo variedad de valores y la distribución de probabilidades dejo de corresponderse con una distribución normal. Por este motivo el método fue descartado. En la figura 4 se muestra la distribución obtenida.
5. *Re-simulación*:
   Para esta técnica valores generados fueron todos válidos, pero la gráfica muestra una asimetría a derecha. En la figura 5 se muestra la distribución obtenida.
6. *Transformación de Datos*:
   Si bien con esta técnica los valores generados fueron todos válidos, no hubo variedad de valores y la distribución de probabilidades dejo de corresponderse con una distribución normal. Por este motivo el método fue descartado. En la figura 6 se muestra la distribución obtenida.

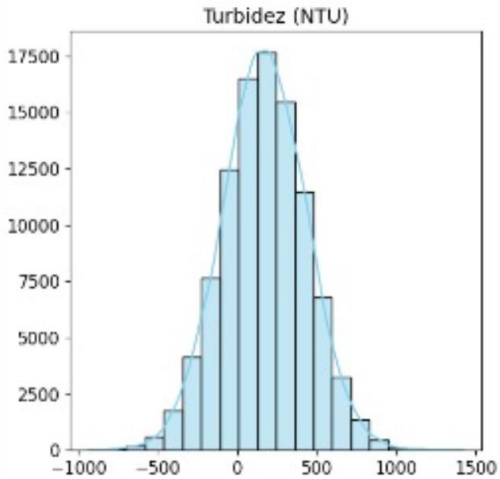

Figura 1: distribución de probabilidad de la variable simulada por el método simulación por defecto donde se observan valores negativos no admisible para la misma

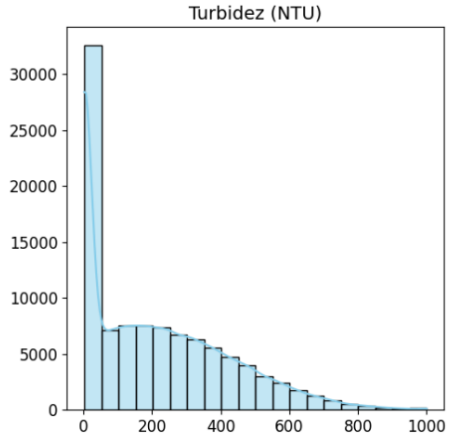

Figura 2: distribución de probabilidad de la variable simulada por el método truncar en valores máximos y mínimos donde se observa que la misma no respeta la distribución normal

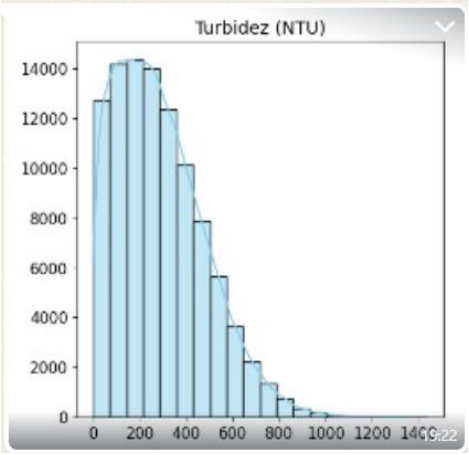

Figura 5: distribución de probabilidad de la variable simulada por el método de resimulación donde se observa una asimetría a dercha

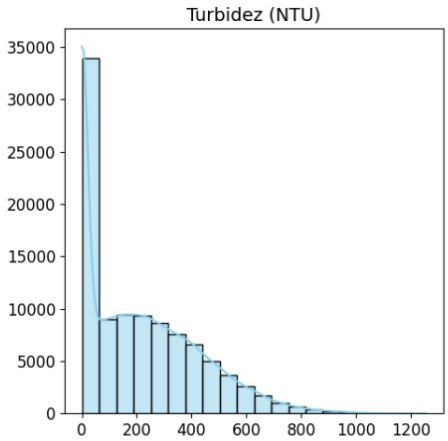

Figura 3: distribución de probabilidad de la variable simulada por el método truncar en cero donde se observa que la misma no respeta la distribución normal

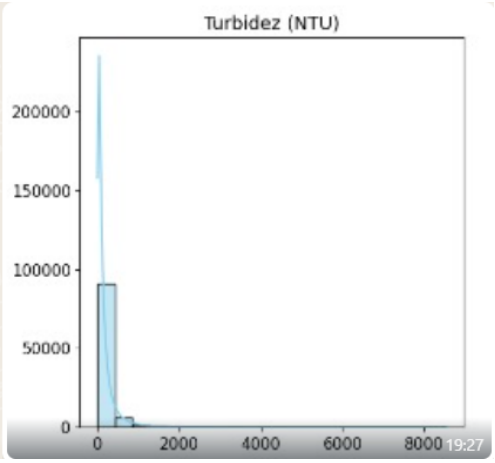

Figura 6: distribución de probabilidad de la variable simulada por el método distribución no negativa donde se observa que la misma no aporta variedad de valores ni respeta la distribución normal

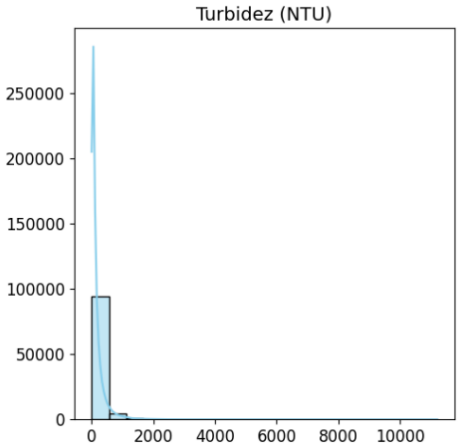

Figura 4: distribución de probabilidad de la variable simulada por el método distribución no negativa donde se observa que la misma no aporta variedad de valores ni respeta la distribución normal

Resultados obtenidos

Después de un exhaustivo análisis del proceso de simulación llevado a cabo, llegamos a la conclusión de que, con la excepción de la técnica de re-simulación, ninguna de las metodologías evaluadas se ajusta de manera óptima a las necesidades del problema actual. Aunque es importante destacar que la técnica de re-simulación produce resultados aceptables en general, se observa un sesgo significativo cuando los valores simulados son inferiores a la media. A pesar de este sesgo, el conjunto de datos generado por el proceso de simulación es válido y adecuado para iniciar los procesos de minería de datos con el

objetivo de identificar patrones de comportamiento iniciales.

A medida que avancen los trabajos de campo y se realicen nuevos muestreos, se llevará a cabo una nueva ejecución de este proceso para observar cómo evoluciona. Es crucial tener en cuenta que parte de las dificultades identificadas hasta el momento están relacionadas con la escasez de muestras disponibles, lo que conlleva una alta varianza asociada a estas muestras. Por lo tanto, se planificarán estrategias para aumentar la cantidad de muestras recolectadas y reducir así la incertidumbre en los resultados obtenidos.

Formación de Recursos Humanos

El equipo de trabajo está formado por dos doctores, dos ingenieros y un estudiante adscripto, que combinan conocimientos en áreas informática y química

Se prevé el trabajo sobre tesis de grado y trabajos profesionales llevados a cabo en la Universidad Nacional del Oeste. El equipo ya ha presentado algunos trabajos relacionados a la presente línea de investigación.

Bibliografía

[1] Carlos Lopez, Enrique Fernandez, Natanael Ferrán, Martín Pastorini, Nicolás Coronel, Marcelo Esperanza; “Análisis del Río de la Reconquista”; Ingeniería Sanitaria y Ambiental, Nro. 149; ISSN 0328 2937; octubre 2023

[2] Richard I. Levin y David S. Rubin ; "Estadística para Administración y Economía"; 2003

[3] García-Pérez, M. A. ; “Introducción a la Simulación Estocástica” ; Editorial Reverté; 2009

[4] Dieste, O., Fernández, E., García-Martínez, R., Juristo; “Comparative Analysis of Meta-Analysis Methods: When to use Which?”; Proceedings 15th Annual Conference on Evaluation & Assessment in Software Engineering (EASE); 2011.

[5] Plá, L.; “Simulación Estocástica y Financiera con Excel”; 2014. Editorial Paraninfo.

[6] Gilks, W., Richardson, S. & Spiegel-halter, D. Markov Chain Monte Carlo in Practice, Chapman & Hall, London

[7] Pardoux, Introduction to Monte Carlo methods for transport and diffusion equations